

**Informe de Consultoría — Sistema 311 Service Requests de la Ciudad de Chicago**  
**Universidad Externado de Colombia · Big Data 2026-I · Allison M. Loango Rayo, Angie K.**  
**Loango Rayo, Rafael J. Orozco Luquez**

### **Contexto y objetivo**

El City of Chicago — Department of Assets, Information and Services contrató el procesamiento del dataset *311 Service Requests* (4.9 GB descomprimido, 13.78 M registros, dic 2018–abr 2026; Chicago Data Portal, v6vf-nfxy) para identificar patrones de demanda, cuellos de botella operativos y construir un modelo de estimación de probabilidad de atención tardía. Clúster propio: 1 maestro + 2 trabajadores, Apache Spark 3.5.7 sobre YARN, HDFS (replicación 2) y PySpark en Jupyter Notebook.

### **Metodología**

El CSV se cargó a HDFS (*hdfs dfs -put*; 39 bloques de 128 MB, nodo2 y nodo3, HEALTHY por *fsck*). SparkSession sobre YARN: `executor.memory=3g`, `executor.cores=2`, `driver.memory=2g`, `shuffle.partitions=100`, `autoBroadcastJoinThreshold=20 MB`, AQE activo, KryoSerializer. Ejecución materializada como **application\_1779304263670\_0002**: 2 executors, 793 tasks sin fallos, 59 min de Task Time agregado. EDA distribuido (esquema, nulos, distribuciones, correlación Pearson, boxplots). Limpieza: filtro `DUPLICATE=false`, parseo de timestamps, exclusión de tiempos negativos y  $>1$  año  $\rightarrow$  13.07 M registros (5.13% de reducción). Tres transformaciones complejas: (T1) broadcast join con tabla de categorías ( $<1$  KB, BroadcastHashJoin confirmado); (T2) window functions `Window.partitionBy(ANIO, MES)` para ranking mensual; (T3) cadena perezosa de seis operaciones para cuellos de botella por ward. Bonificación: pipeline MLlib (`StringIndexer [SR_TYPE, CATEGORIA, WARD, ORIGIN, CREATED_DAY_OF_WEEK]`  $\rightarrow$  `OneHotEncoder`  $\rightarrow$  `VectorAssembler`  $\rightarrow$  `RandomForest`, 80 árboles, `maxDepth=10`, `maxBins=128`) entrenado en 81.6 s sobre muestreo del 5% ( $\sim 374$  k filas; clase positiva 17.6%).

### **Resultados clave**

(i) **Volumen concentrado**: 5 tipos explican  $>63\%$  (311 INFORMATION ONLY CALL 35.7%, Aircraft Noise 17.3%, Graffiti Removal 4.9%, Pothole 2.9%, Street Light Out 2.8%). (ii) **Cierre**: 97.1%; canal dominante Phone Call 57.1%, Internet 27.1%, Mobile 7.6%. (iii) **Temporal**: caída COVID-19, estacionalidad anual (abr–sep), tendencia creciente desde 2023. (iv) **Geográfico**: 10 wards concentran 26.1%–30.9% de respuestas tardías relativas (P75 por tipo); liderados por ward 34. (v) **Modelo**: AUC-ROC=0.8061, accuracy=0.8246; SR\_TYPE (42.5%), WARD (25.6%), ORIGIN (21.1%). (vi) **Técnico**: Stage 66 (broadcast join + agregación) y Stage 69 más costosos ( $\sim 24$  s c/u, 60.4 MiB y 8.2 MiB shuffle write); stage Window (T2) con spill a disco  $\sim 80$  MB confirmado en Spark UI.

### **Conclusiones y recomendaciones**

Eficiencia agregada alta (97% cierre) con heterogeneidad estructural por ward no aleatoria. Recomendaciones: (1) re-balancear cuadrillas usando %TARDIOS por ward; (2) **pilotear** el score del modelo (AUC 0.81) para alertar casos con probabilidad  $>0.70$  de incumplir SLA, con monitoreo de drift trimestral antes de producción; (3) reforzar canal móvil/web; (4) normalizar a NULL campos  $>50\%$  nulos. **Limitaciones**: modelo predictivo, no causal; drift COVID en 2020–2021.

### **Declaración de uso de Inteligencia Artificial**

En cumplimiento de la Comunicación rectoral n.º 004 (Universidad Externado de Colombia), uso categorizado como *Revisado con IA* y *Corregido con IA* (Claude, Anthropic) en código PySpark, análisis y redacción. Selección del dataset, configuración del clúster y decisiones metodológicas sin asistencia de IA. Detalle en Anexo I del documento complementario.

**Video**: <https://youtu.be/CMURRUNDDSU?feature=shared> · **Anexos**: PDF complementario adjunto. ·

**Código**: [chicago311\\_bigdata\\_FINAL.ipynb](#) adjunto.